

# Практична робота №3

**Тема:** Класифікація твітів за тональністю з використанням Word2Vec та scikit-learn моделей

**Предмет:** Машинне навчання

**Рівень:** 4 рік навчання

**Датасет:** [COVID-19 NLP Text Classification Dataset](#)

## 1. Постановка задачі

Ми маємо колекцію твітів про COVID-19 з такими колонками:

1. **Location** – місце, звідки опубліковано твіт.
2. **Tweet At** – дата публікації.
3. **Original Tweet** – текст повідомлення.
4. **Label (Sentiment)** – цільова змінна, яка може набувати значень: *Negative*, *Positive*, *Other*.

**Завдання:** побудувати класифікаційні моделі для прогнозування тональності (Sentiment) твітів.

**Особливість:** на вхід моделі подаються **векторні представлення текстів (embeddings)**, отримані з допомогою **Word2Vec (gensim [Link](#))**. Додатково потрібно дослідити, як **зниження розмірності ознак за допомогою PCA** впливає на точність класифікації.

## 2. Покрокова інструкція

### 2.1. Підготовка даних

1. Завантажте датасет.
2. Виконайте попередню обробку тексту (очистка від стоп-слів, приведення до нижнього регістру, токенизація).

3. Навчіть модель **Word2Vec** (або використайте попередньо треновану) для отримання векторних представлень слів.
4. Для кожного твіту сформууйте вектор (наприклад, середнє арифметичне embedding-ів усіх слів у повідомленні).
5. Поділіть дані на тренувальну та тестову вибірки (80/20).

## 2.2. Побудова моделей

Реалізуйте **scikit-learn pipeline**, який включає:

- етап побудови ознак (Word2Vec + опційно PCA),
- етап класифікації.

Необхідно навчити та порівняти **4 моделі**:

1. Logistic Regression
2. Support Vector Machine (SVM)
3. Random Forest
4. Naive Bayes

## 2.3. Експеримент з PCA

1. Виконайте класифікацію без зниження розмірності.
2. Виконайте класифікацію після застосування PCA (наприклад, до 50, 100 та 200 компонент).
3. Порівняйте результати.

## 3. Метрики оцінки

Для оцінки моделей використовуйте:

- **Accuracy**

- **Precision, Recall, F1-score** (для кожного класу)
- **Confusion Matrix** (для наочності)

Результати зручно подати у вигляді таблиці: моделі × метрики × кількість компонент PCA.

Новий текст потрібно **пропустити через ті ж самі кроки обробки**, що і тренувальні дані: очистка → токенизація → Word2Vec-вектор.

Якщо у фінальній моделі використовувалось **PCA** — його теж потрібно додати у пайплайн для нових даних.

Вихід — клас (*Positive / Negative / Other*).

## 4. Представлення результатів

У Jupyter Notebook необхідно подати:

1. Код підготовки даних, навчання моделей та оцінки результатів.
2. Таблиці з метриками для всіх моделей.
3. Графіки впливу розмірності PCA на точність класифікації.
4. Confusion Matrix для найкращої моделі.
5. Висновки:
  - яка модель показала найкращий результат;
  - чи покращило/погіршило PCA якість класифікації;
  - інтерпретація отриманих результатів.